Лекция 4

Синтаксически управляемая трансляция (3)

Курносов Михаил Георгиевич

www.mkurnosov.net

Сибирский государственный университет телекоммуникаций и информатики Весенний семестр

Лексический анализатор для транслятора простых выражений

- Лексический анализатор считывает символы из входной строки и группирует их в токены (token) терминал с дополнительными атрибутами (тип токена, лексема)
- Расширение грамматики: идентификаторы, целочисленные литералы

- **num**.*value* атрибут терминала **num** со значением целочисленного литерала в десятичной системе исчисления
- id.lexeme строковый атрибут терминала id со значением идентификатора

Лексический анализатор: пропуск пробельных символов

```
Token Lexer::nextToken()
    // Пропуск пробельных символов
    for ( ; ; peek = readNextChar()) {
      if (peeκ == ' ' || peak == '\t')
          continue;
      else if (peek == '\n')
          line = line + 1;
      else
          break;
    // ...
    return Token(tokenType, lexeme)
```

Лексический анализатор: опережающее чтение

- Распознавание лексем с общим префиксом: >, >=, >>, ...
- Лексическому анализатору может требоваться прочесть несколько символов за текущим, чтобы решить, какой именно токен следует вернуть
- Опережающее чтение (reading ahead) поддержка входного буфера, из которого анализатор может выполнять чтение и в который может возвращать прочитанные символы
- Альтернатива буфер с *N* вперед прочитанными символами + указатель на текущий символ

Целочисленные литералы (константы)

```
Вход анализатора: 31 + 28 + -59
 Выход: <num, 31> <plus> <num, 28> <plus> <minus> <num, 59>
    // Целочисленный литерал в десятичной системе исчисления
    if (isDigit(peek))
        value = 0
        do {
            value = value * 10 + strToInt(peek) // Целочисленное значение цифры
            peak = readNextChar();
        } while (isDigit(peek))
        return Token(NUM, value)
bool isDigit(char ch)
    return ch == '0' || ch == '1' || ... || ch == '9';
```

Clang

https://clang.llvm.org/doxygen/Lexer 8cpp source.html

```
2028 /// LexNumericConstant - Lex the remainder of a integer or floating point
2029 /// constant. From[-1] is the first character lexed. Return the end of the
2030 /// constant.
2031
     bool Lexer::LexNumericConstant(Token &Result, const char *CurPtr) {
2032
        unsigned Size:
2033
        char C = getCharAndSize(CurPtr, Size);
2034
        char PrevCh = 0;
2035
        while (isPreprocessingNumberBody(C)) {
2036
          CurPtr = ConsumeChar(CurPtr, Size, Result);
2037
          PrevCh = C:
          if (LangOpts.HLSL && C == '.' && (*CurPtr == 'x' || *CurPtr == 'r')) {
2038
2039
            CurPtr -= Size:
2040
            break:
2041
2042
           = getCharAndSize(CurPtr, Size);
2043
2044
2045
        // If we fell out, check for a sign, due to 1e+12. If we have one, continue.
        if ((C == '-' || C == '+') && (PrevCh == 'E' || PrevCh == 'e')) {
2046
2047
         // If we are in Microsoft mode, don't continue if the constant is hex.
2048
          // For example, MSVC will accept the following as 3 tokens: 0x1234567e+1
2049
         if (!LangOpts.MicrosoftExt || !isHexaLiteral(BufferPtr, LangOpts))
            return LexNumericConstant(Result, ConsumeChar(CurPtr, Size, Result));
2050
2051
2052
2053
        // If we have a hex FP constant, continue.
2054
        if ((C == '-' || C == '+') && (PrevCh == 'P' || PrevCh == 'p')) {
2055
          // Outside C99 and C++17, we accept hexadecimal floating point numbers as a
2056
          // not-quite-conforming extension. Only do so if this looks like it's
          // actually meant to be a hexfloat, and not if it has a ud-suffix.
2057
2058
          bool IsHexFloat = true;
2059
          if (!LangOpts.C99) {
2060
            if (!isHexaLiteral(BufferPtr, LangOpts))
2061
              IsHexFloat = false;
            else if (!LangOpts.CPlusPlus17 &&
2062
2063
                     std::find(BufferPtr, CurPtr, ' ') != CurPtr)
              IsHexFloat = false;
2064
2065
          if (IsHexFloat)
2066
2067
            return LexNumericConstant(Result, ConsumeChar(CurPtr, Size, Result));
2068
```

Распознавание ключевых слов и идентификаторов

- **Ключевое слово** (keyword) фиксированные символьные строки для обозначения языковых конструкций или синтаксических знаков препинания
- Примеры: for, do, while, if, else, then
- Грамматики обычно трактуют идентификаторы как терминалы для упрощения синтаксического анализатора
- Два варианта
 - 1. Ключевые слова зарезервированы, идентификаторы не могут совпадать с ключевыми словами
 - 2. Идентификаторы могут совпадать с ключевыми словами (APL, PL/I, Fortran: https://fortranwiki.org/fortran/show/Keywords)

Хранение ключевых слов и идентификаторов в одной таблице символов

```
if (isAlpha(peek)) {
        // Собираем буквы или цифры в буфер str
        // Предполагается, что строка str должна быть максимально
        // возможной длины, анализатор продолжает чтение до тех пор,
        // пока считываются буквы и цифры
        str = peek
        for (peek = readNextchar(); isAlphaNum(peek); peek = readNextchar())
             str += peek
        token = symbolTable.lookup(str)
        if (!token) {
            token = Token(IDENT, str)
            symbolTable.add(str, token)
        return token;
bool isAlpha(char ch)
   return ch == 'a' || ch == 'A' || ch == 'b' || ... || ch == 'Z';
```

Ключевые слова заранее внесены в таблицу символов (symbol table)

#	Symbol	Token
1	if	(KW_IF, 0)
2	then	(KW_THEN, 0)
3	for	(KW_FOR, 0)
	•••	•••
78	nUsers	(IDENT, 'nUsers')
79	sum	(IDENT, 'sum')

Структура основной функции лексического анализатора

Таблица символов

- **Таблица символов** (symbol table) структура данных, которая хранит информацию о конструкциях исходной программы
- Таблица заполняется и модифицируется инкрементно на начальной стадии работы компилятора
- Записи в таблице символов:
 - о информацию об идентификаторах
 - о местоположение в памяти
- Поддержка множественных объявлений одного и того же идентификатора (отдельная таблица символов для каждой области видимости)
- Операции:
 - о Добавление символа с указанием типа токена
 - Поиск по символу

Область видимости (scope)

- **Правило последнего вложения** (most-closely nested) для блоков идентификатор *х* находится в области видимости последнего по вложенности объявления *х*
- Определение идентификатора следует искать путем перебора блоков изнутри наружу (снизу вверх),
 начиная с блока, в котором находится интересующий идентификатор
- Реализация таблиц символов для вложенных блоков:
 - о **Стек локальных таблиц символов**: на вершине стека находится таблица для текущего блока, ниже в стеке располагаются таблицы охватывающих блоков
 - **Единая хеш-таблица**: при выходе из блока компилятор должен отменить все изменения, внесенные в хеш-таблицу объявлениями в блоке (вспомогательный стек для отслеживания изменений в хеш-таблице при обработке блока)

```
1) { int x_1; int y_1;

2) { int w_2; bool y_2; int z_2;

3) \cdots w_2 \cdots; \cdots x_1 \cdots; \cdots y_2 \cdots; \cdots z_2 \cdots;

4) }


5) \cdots w_0 \cdots; \cdots x_1 \cdots; \cdots y_1 \cdots;

6) }
```

Два вложенных блока:

- Блок 1: x₁, y₁,
- Блок 2: w₂, y₂, z₂
- Блок 0 (внешний): w₀

 Реализация правила ближайшего вложенного блока на базе цепочек таблиц символов — таблица для вложенного блока указывает на таблицу для охватывающего блока (outer)




```
1) { int x_1; int y_1; Cоздание B_1
2) { int w_2; bool y_2; int z_2;
3) \cdots w_2 \cdots; \cdots x_1 \cdots; \cdots y_2 \cdots; \cdots z_2 \cdots;
4) }
5) \cdots w_0 \cdots; \cdots x_1 \cdots; \cdots y_1 \cdots;
6) }
```

Два вложенных блока:

- Блок 1: x₁, y₁,
- Блок 2: w₂, y₂, z₂
- Блок 0 (внешний): w₀

 Реализация правила ближайшего вложенного блока на базе цепочек таблиц символов — таблица для вложенного блока указывает на таблицу для охватывающего блока (outer)




вложенного блока на базе цепочек таблиц символов — таблица для вложенного блока указывает на таблицу для охватывающего блока (outer)

Реализация правила ближайшего

Два вложенных блока:


- Блок 1: x₁, y₁,
- Блок 2: w₂, y₂, z₂
- Блок 0 (внешний): w₀



 Реализация правила ближайшего вложенного блока на базе цепочек таблиц символов — таблица для вложенного блока указывает на таблицу для охватывающего блока (outer)

Два вложенных блока:

- Блок 1: x₁, y₁,
- Блок 2: w₂, y₂, z₂
- Блок 0 (внешний): w₀



Реализация цепочки таблиц символов

```
package symbols;
import java.util.*;
public class Env {
   private Hashtable table;
   protected Env prev;
   public Env(Env p) {
      table = new Hashtable(); prev = p;
   public void put(String s, Symbol sym) {
      table.put(s, sym);
   public Symbol get(String s) {
      for( Env e = this; e != null; e = e.prev ) {
         Symbol found = (Symbol)(e.table.get(s));
         if( found != null ) return found;
      return null;
```




Схема трансляции с использованием таблиц символов

```
\{ top = null; \}
program
                 block
   block \rightarrow
                                    \{ saved = top; \}
                                                                   Создание новой
                                      top = \mathbf{new} \; Env(top);
                                                                   таблицы
                                      print(" { "); }
                 decls stmts '}'
                                   \{ top = saved; 
                                                                   Переключение
                                      print(" } "); }
                                                                   на предыдущую
                                                                   таблицу
                 decls decl
   decls
                                   \{ s = \mathbf{new} \ Symbol; \}
    decl
               type id;
                                                                    Добавление имени
                                      s.type = type.lexeme
                                                                   переменной в
                                      top.put(id.lexeme, s);
                                                                   текущую таблицу
                 stmts stmt
    stmts
                 block
    stmt
                 factor;
                                    { print("; "); }
                                    \{ s = top.get(id.lexeme); \}
  factor \rightarrow
                                                                     Поиск имени в
                                      print(id.lexeme);
                                                                     цепочке таблиц
                                      print(":");
                                                                     СИМВОЛОВ
                                      print(s.type);
```

```
int x; char y;
  bool y; x; y;
x; y;
       Схема трансляции удаляет
      объявления и выдает строку —
        связывает использование
      переменных с определениями
         (отыскивает в таблицах
               символов)
  x:int; y:bool;
x:int; y:char;
```


Генерация промежуточного кода


- Два вида промежуточных представлений (intermediate representation IR)
 - о деревья разбора, абстрактные синтаксические деревья
 - линейные представления трехадресный код
- Компилятор может строить синтаксическое дерево одновременно с генерацией трехадресного кода

Дерево разбора —> Синтаксическое дерево —> Трехадресный код

Абстрактное синтаксическое дерево

Дерево разбора (parse tree) — древовидное представление порождения строки языка из стартового символа грамматики







Абстрактное синтаксическое дерево

(abstract syntax tree) — древовидное представление порождения строки языка, в котором узлами являются программные конструкции

Абстрактное синтаксическое дерево разбора для строки «9-5+2»



Построение синтаксических деревьев для выражений и инструкций



Построение синтаксических деревьев для выражений и инструкций


```
program \rightarrow block
                                   { return block.n; }
   block \rightarrow '\{'stmts'\}'
                                   \{ block.n = stmts.n; \}
                                   \{ stmts.n = \mathbf{new} \ Seq (stmts_1.n, stmt.n); \}
    stmts \rightarrow stmts_1 stmt
                                   \{ stmts.n = null; \}
                                   \{ stmt.n = \mathbf{new} \ Eval (expr.n); \}
    stmt \rightarrow expr;
                 if ( expr ) stmt_1
                                   \{ stmt.n = new \ If(expr.n, stmt_1.n); \}
                 while (expr) stmt<sub>1</sub>
                                   \{ stmt.n = new While (expr.n, stmt_1.n); \}
                 do stmt_1 while ( expr );
                                    \{ stmt.n = \mathbf{new} \ Do (stmt_1.n, expr.n); \}
               block
                                   \{ stmt.n = block.n; \}
    expr \rightarrow rel = expr_1
                                  { expr.n = new Assign ('=', rel.n, expr_1.n); }
                                  \{ expr.n = rel.n; \}
               rel
      rel \rightarrow rel_1 < add
                                  { rel.n = new Rel(' < ', rel_1.n, add.n); }
                                   { rel.n = new Rel(' \leq ', rel_1.n, add.n); }
               rel_1 \le add
                                   \{ rel.n = add.n; \}
               add
     add \rightarrow add_1 + term
                                   { add.n = new Op('+', add_1.n, term.n); }
                                   \{ add.n = term.n; \}
               term
    term \rightarrow term_1 * factor
                                  { term.n = new Op('*', term_1.n, factor.n); }
                                   \{ term.n = factor.n; \}
               factor
  factor \rightarrow (expr)
                                  \{ factor.n = expr.n; \}
                                   { factor.n = new Num (num.value); }
                num
```

```
stmt \rightarrow block { stmt.n = block.n; } block \rightarrow '\{'stmts'\}' { block.n = stmts.n; }
```

- Первое правило если инструкция представляет собой блок, то она имеет то же синтаксическое дерево, что и блок
- Второе правило синтаксическое дерево для нетерминала block представляет собой просто синтаксическое дерево для последовательности инструкций в блоке

Построение синтаксических деревьев для выражений и инструкций

```
program \rightarrow block
                                  { return block.n; }
   block \rightarrow '\{' stmts'\}'
                                  \{ block.n = stmts.n; \}
                                  { stmts.n = new Seq (stmts_1.n, stmt.n); }
   stmts \rightarrow stmts_1 stmt
                                  \{ stmts.n = null; \}
                                  \{ stmt.n = new Eval(expr.n); \}
    stmt \rightarrow expr;
                if ( expr ) stmt_1
                                  \{ stmt.n = new \ If(expr.n, stmt_1.n); \}
                while (expr) stmt_1
                                  \{ stmt.n = new While (expr.n, stmt_1.n); \}
                do stmt1 while (expr);
                                   \{ stmt.n = \mathbf{new} \ Do (stmt_1.n, expr.n); \}
                                  \{ stmt.n = block.n; \}
               block
    expr \rightarrow rel = expr_1
                                  { expr.n = new Assign ('=', rel.n, expr_1.n); }
                                  \{ expr.n = rel.n; \}
              rel
                                  { rel.n = new Rel(' < ', rel_1.n, add.n); }
      rel \rightarrow rel_1 < add
               rel_1 \le add
                                  { rel.n = new Rel(' \leq ', rel_1.n, add.n); }
                                  \{ rel.n = add.n; \}
               add
     add \rightarrow add_1 + term
                                  { add.n = new Op('+', add_1.n, term.n); }
                                  \{ add.n = term.n; \}
               term
    term \rightarrow term_1 * factor
                                  { term.n = new Op('*', term_1.n, factor.n); }
                                  \{ term.n = factor.n; \}
              factor
                                  \{ factor.n = expr.n; \}
  factor \rightarrow (expr)
                                  { factor.n = new Num (num.value); }
               num
```



Часть синтаксического дерева для списка инструкций, состоящего из инструкций **if** и **while**

- Все нетерминалы в схеме трансляции имеют атрибут п
 узел синтаксического дерева (объект класса Node)
- Класс Seq последовательность инструкций
- Класс Node имеет два подкласса:
 - о Ехрг для выражений всех видов
 - Stmt для всех видов инструкций (подклассы If, While, Do)

Статические проверки (static checking)

- На этапе лексического и синтаксического анализа выполняются статические проверки (static checking)
- Проверка синтаксиса (syntactic checking) уникальность идентификаторов в области видимости, расположение инструкций в допустимых местах (break только в цикле или switch) эти требования не покрываются грамматикой
- Проверка типов (type checking) проверка корректности применения оператора/функции к корректному числу операндов допустимых и совместимых типов; преобразования типов (добавление соответствующего оператора в синтаксическое дерево: intToFloat, shortToInt)

```
if (a > 4) i = 3 // (a > 4) — должно быть типа boolean if (3) i = 3 // (3), intToBool(int) — должно быть типа boolean
```


- о **Приведения** (coercion): 3 * 2.17 ==> intToDouble(3) * 2.17 (Определение языка указывает, какие именно приведения допустимы)
- Перегрузка (overloading): поиск операции для операндов
- Проверка L-значений и R-значений: левая сторона оператора присваивания имеет L-значение (l-value)

Абстрактное синтаксическое дерево

name: b

name: b

name: a



variable name: a Варианты дальнейшего анализаи синтеза после построения синтаксического дерева (AST):

- генерация кода для целевой системы
- генерация кода в линейное промежуточное представления (линеаризация)

Трёхадресный код (three-address instructions)

Арифметико-логические команды и команды доступа к памяти

```
    x = y ор z // x, y, z - константы или имена переменных
    x[y] = z // запись z в элемент y массива x
    x = y[z] // чтение в x элемент z массива y
    x = y // копирование y в x
```

Команды изменения потока управления (control flow)

```
    ifFalse x goto L // Если x ложно, следующей выполняется команда с меткой L
    ifTrue x goto L // Если x истинно, следующей выполняется команда с меткой L
    goto L // Следующей выполняется команда с меткой L
    L: x // Указание метки команде x
```

Трансляция инструкций: if

```
if (expr) stmt1 → Код вычисления expr во временную переменную cond ifFalse cond goto AFTER
Код stmt1
AFTER:
```

```
class If extends Stmt {
    Expr E; Stmt S;
    public If(Expr x, Stmt y) { E = x; S = y; after = newlabel(); }
    public void gen() {
        Expr n = E.rvalue();
        emit("ifFalse" + n.toString() + " goto" + after);
        S.gen();
        emit(after + ":");
    }
}
```

- Конструктор If создает узел синтаксического дерева
- Функция gen вызывается для генерации трехадресного кода
- После построение всего синтаксического дерева в его корне вызывается функция gen

Трансляция инструкций: выражения

 Для констант и идентификаторов не генерируется никакой код — они входят в команды в качестве адресов

■ Если узел х класса Ехрг содержит оператор ор, то генерируется команда для вычисления значения в узле х во "временное" имя t

$$i - j + k$$
 \longrightarrow $t1 = i - j$
 $t2 = t1 - k$

- При обращении к массивам и присваиваниях требуется различать l-значения и r-значения
- Выражение 2 * a[i] может быть транслировано путем вычисления r-значения a[i] во временную переменную

$$2 * a[i]$$
 \longrightarrow $t1 = a[i]$ $t2 = 2 * t1$

 Нельзя использовать временную переменную вместо a[i], если a[i] появляется в левой части присваивания

Трансляция инструкций: выражения

 Функция lvalue() — генерирует команды для вычисления поддеревьев ниже х и возвращает узел, представляющий "адрес" х

```
Expr lvalue(x : Expr) {
    if (x является узлом Id) return x;
    else if (x является узлом Access(y, z), а y - ysen Id) {
        return new Access(y, rvalue(z));
    }
    else error;
}

a[2 * k]

t = 2 * k
a[t]
```

Трансляция инструкций: выражения

 Функция rvalue() — генерирует команды для вычисления х во временную переменную и возвращает новый узел, представляющий эту переменную

```
Expr rvalue(x : Expr)  {
     if ( x — узел Id или Constant ) return x;
     else if ( x — узел Op(\mathbf{op}, y, z) или Rel(\mathbf{op}, y, z) ) {
           t = новая временная переменная;
           Генерация строки для t = rvalue(y) ор rvalue(z);
           return Новый узел t;
     else if ( x узел Access(y, z) ) {
          t = новая временная переменная;
           Вызов lvalue(x) возвращающий Access(y, z');
           Генерация строки для t = Access(y, z');
          return Новый узел t;
     else if (x - yзел Assign (y, z)) {
          z' = rvalue(z);
          Генерация строки для lvalue(y) = z';
          return z';
```

